# Poszukiwanie największej kliki w grafie

# Anna Stępień Adam Stelmaszczyk

# Spis treści

1	Zadanie	
2	Założenia 2.1 Dane wejściowe	. 2
	2.2 Dane wyjściowe	
	2.3 Sytuacje wyjątkowe	
3	Algorytm	3
	3.1 Pseudokod	. 3
	3.2 Opis działania	
	3.3 Złożoność	. 5
4	Struktury danych	6
5	Testy	6
	5.1 Badanie poprawności zwracanych wyników	. 6
	5.2 Badanie czasu wykonania dla różnych typów grafów	
6	Analiza zaimplementowanego algorytmu	6
	6.1 Analiza poprawności działania algorytmu	. 7
	6.2 Analiza czasów wykonania algorytmu	
7	Podsumowanie i wnioski	23
D	odatek A Zawartość katalogów	23
D	odatek B Instrukcja obsługi	23

### 1 Zadanie

Kliką grafu nazywamy podgraf, w którym każde dwa wierzchołki są ze sobą połączone. Maksymalną kliką nazywamy klikę, do której nie można dodać ani jednego wierzchołka więcej, tak aby razem z nią nadal tworzył klikę. Największą kliką nazywamy klikę o największej liczbie wierzchołków. Celem zadania jest implementacja wybranego algorytmu znajdującego największa klikę w grafie oraz analiza otrzymanych wyników.

#### 2 Założenia

Realizowana aplikacja będzie pracowała w trybie konsolowym i będzie przyjmowała pliki z danymi przekazane na strumień wejściowy.

W projekcie zostanie wykorzystany zmodyfikowany algorytm Brona–Kerboscha [1], dokładniej opisany w sekcji 3. Do implementacji zadania wykorzystany zostanie jezyk Java.

#### 2.1 Dane wejściowe

Wejściem dla algorytmu jest graf nieskierowany dany macierzą o n wierszach i n kolumnach:

 $q_{i,j}$  równe 0 oznacza, że wierzchołki i oraz j nie są połączone krawędzią. W przeciwnym razie, wierzchołki są połączone.

Macierz jest dana w pliku tekstowym, w którym kolejne  $q_{i,j}$  w wierszu j są oddzielone co najmniej jednym znakiem białym. Przez znak biały rozumiemy spację lub tabulator.  $q_{i,j}$  różne od 0 będą traktowane jak 1.

Poniżej przedstawiono przykładowy, poprawny plik wejściowy.

# 2.2 Dane wyjściowe

Wyjściem jest niepusty zbiór numerów wierzchołków, które tworzą największą klikę w podanym grafie. Wierzchołki numerujemy od 0 do n-1. W grafie może istnieć więcej niż jedna największa klika. W takim przypadku algorytm zwróci pierwszą ze znalezionych klik.

#### 2.3 Sytuacje wyjątkowe

Problemami, które mogą wystąpić podczas działania aplikacji są:

- błędny format danych wejściowych,
- przepełnienie stosu spowodowane zbyt głębokim poziomem rekurencji.

W przypadku, gdy algorytm otrzyma na wejściu błędne dane np. liczba wierszy macierzy będzie niezgodna z zadeklarowaną na początku pliku z danymi, użytkownik zostanie poinformowany o zaistniałej sytuacji a dalsze działanie programu zostanie przerwane.

Ze względu na rekurencyjny charakter algorytmu Brona–Kerboscha może się zdarzyć, iż dla pewnych danych wejściowych algorytm nie będzie w stanie zwrócić wyniku ze względu na ograniczoną pojemność stosu. Próbą rozwiązania tego problemu mogłaby być iteracyjna implementacja algorytmu.

# 3 Algorytm

Algorytm Brona–Kerboscha jest rekurencyjnym algorytmem z nawrotami, który umożliwia poszukiwanie maksymalnych klik w zadanym grafie niezorientowanym. Domyślnie algorytm zwraca wszystkie maksymalne kliki. W algorytmie wprowadzona zostanie zmiana, dzięki której zwracana będzie największa ze znalezionych maksymalnych klik, charakteryzująca się największą liczbą wierzchołków.

#### 3.1 Pseudokod

Na poniższym listingu przedstawiona została podstawowa wersja algorytmu Brona–Kerboscha.

Poniżej przedstawiona została zmodyfikowana wersja algorytmu, która zostanie wykorzystana do realizacji zadania.

#### 1 Algorytm Brona–Kerboscha (wersja podstawowa)

```
1: compsub \leftarrow \emptyset
 2: candidates \leftarrow V(G)
 3: not \leftarrow \emptyset
 4: cliques \leftarrow \emptyset
 5: function BRON_KERBOSCH(compsub, candidates, not)
        if candidates = \emptyset and not = \emptyset then
             cliques \leftarrow cliques \cup \{compsub\}
                                                                              ⊳ Maksymalna klika
 7:
 8:
         else
             for each v in candidates do
 9:
10:
                 candidates \leftarrow candidates \setminus \{v\}
                 new\_compsub \leftarrow compsub \cup \{v\}
11:
                 new\_candidates \leftarrow candidates \cap neighbors(v)
12:
                 new\_not \leftarrow not \cap neighbors(v)
13:
                 BRON_KERBOSCH(new_compsub, new_candidates, new_not)
14:
                 compsub \leftarrow compsub \cup \{v\}
15:
             end for
16:
         end if
17:
18: end function
```

#### 2 Algorytm Brona–Kerboscha (wersja rozszerzona)

```
1: compsub \leftarrow \emptyset
 2: candidates \leftarrow V(G)
 3: not \leftarrow \emptyset
 4: biggest\_clique \leftarrow \emptyset
 5: function BRON_KERBOSCH(candidates, not)
        if candidates = \emptyset and not = \emptyset then
 6:
 7:
             if size(biggest\_clique) < size(compsub) then
                 biggest\_clique \leftarrow compsub
                                                                                 ⊳ Największa klika
 8:
             end if
 9:
        else
10:
             pivot \leftarrow vertex\_with\_maxdeg(candidates \cup not)
11:
             candidates\_to\_check \leftarrow candidates \setminus neighbors(pivot)
12:
             for each v in candidates_to_check do
13:
14:
                 compsub \leftarrow compsub \cup \{v\}
                 candidates \leftarrow candidates \setminus \{v\}
15:
                 new\_candidates \leftarrow candidates \cap neighbors(v)
16:
                 new\_not \leftarrow not \cap neighbors(v)
17:
                 BRON_KERBOSCH(new_candidates, new_not)
18:
                 compsub \leftarrow compsub \setminus \{v\}
19:
                 not \leftarrow not \cup \{v\}
20:
             end for
21:
         end if
22:
23: end function
```

#### 3.2 Opis działania

Istotą działania przedstawionego algorytmu jest utrzymywanie trzech rozłącznych zbiorów: compsub, candidates oraz not.

Algorytm Brona–Kerboscha znajduje maksymalne kliki składające się ze wszystkich wierzchołków należących do zbioru *compsub*, niektórych należących do zbioru *candidates*, i z żadnego, który należy do zbioru *not*.

Poniżej przedstawiona została charakterystyka każdego ze zbiorów wykorzystywanych przez algorytm:

#### • compsub

do zbioru należą wszystkie wierzchołki grafu, które tworzą powstającą klikę.

#### • candidates

do zbioru należą wierzchołki grafu, które mogą posłużyć do rozszerzenia zbioru compsub.

#### not

do zbioru należą te wierzchołki, które były już wcześniej wykorzystane do rozszerzenia zbioru compsub.

Należy zauważyć, iż wszystkie wierzchołki, które są połączone z każdym wierzchołkiem należącym do zbioru *compsub* znajdują się albo w zbiorze *candidates* albo not.

Zmodyfikowana wersja algorytmu Brona–Kerboscha wprowadza pojęcie wierzchołka zwrotnego (dalej oznaczanego pivot), który wybierany jest ze zbioru  $candidates \cup not$ jako wierzchołek o największym stopniu.

W każdym rekurencyjnym wywołaniu algorytmu rozważane są wierzchołki należące do zbioru candidates. Jeśli zbiory candidates i not są puste, sprawdzane jest czy znaleziona maksymalna klika (oparta na wierzchołkach ze zbioru compsub) jest większa od największej dotychczas znalezionej kliki. Jeśli tak, to znaleziona klika staje się największą, w przeciwnym wypadku największa klika pozostawiana jest bez zmian. W przypadku, gdy zbiory candidates i not nie są puste, dla każdego wierzchołka ze zbioru  $candidates \setminus neighbors(pivot)$  następuje rekurencyjne wywołanie algorytmu, w którym bieżący wierzchołek v dodawany jest do zbioru compsub i usuwany ze zbioru candidates, a w zbiorach candidates i not pozostawiane są tylko te wierzchołki grafu, które są sąsiadami wierzchołka v. Następnie, wierzchołek v jest dodawany do zbioru not jako już wykorzystany do rozszerzenia kliki oraz usuwany ze zbioru compsub.

Wynikiem działania algorytmu jest zbiór biggest\_clique, który początkowo inicjowany jest jako zbiór pusty. W przypadku, gdy znaleziona zostanie największa klika, zbiór ten zawiera wierzchołki ją tworzące.

#### 3.3 Złożoność

Pesymistyczna złożoność przedstawionego algorytmu wynosi  $O(3^{n/3})$  i wynika z górnego ograniczenia na liczbę maksymalnych klik w grafie o n wierzchołkach.

# 4 Struktury danych

**Graf** Do reprezentacji grafu zostanie wykorzystana macierz sąsiedztwa, zaimplementowana jako dwuwymiarowa tablica wartości boolowskich.

**Zbiory wierzchołków** (compsub, candidates, not, biggest\_clique) Zbiory przechowujące wierzchołki zostaną zaimplementowane jako klasa Vertices dziedzicząca po klasie TreeSet języka Java.

# 5 Testy

Istotną częścią realizowanego zadania jest przeprowadzenie testów związanych zarówno z poprawnością zwracanych wyników jak również wpływem danych wejściowych na czas wykonania algorytmu.

#### 5.1 Badanie poprawności zwracanych wyników

Do weryfikacji poprawności zwracanych przez algorytm wyników zostanie wykorzystana biblioteka igraph<sup>1</sup>, która udostępnia m.in funkcję wyznaczającą maksymalne kliki w zadanym grafie. Podczas testowania planujemy wykorzystać dane zwrócone przez bibliotekę igraph jako rozwiązania referencyjne, które następnie posłużą do porównania z wynikami otrzymanymi przez zaimplementowany algorytm. Rozwiązanie, a więc największa klika zwrócona przez algorytm jest poprawna wtedy, gdy znajduje się na liście rozwiązań referencyjnych.

Proces generowania rozwiązań referencyjnych oraz porównywania wyników zostanie zautomatyzowany.

# 5.2 Badanie czasu wykonania dla różnych typów grafów

Z punktu widzenia analizy zaimplementowanego algorytmu istotne jest zbadanie jego zachowania dla różnych typów grafów. W szczególności przeprowadzone zostaną eksperymenty na zestawach grafów o zróżnicowanej gęstości.

# 6 Analiza zaimplementowanego algorytmu

W ramach części badawczej projektu zrealizowane zostały dwa rodzaje testów: testy wykazujące poprawność implementacji algorytmu oraz testy badające jego zachowanie dla różnych typów grafów.

W obu eksperymentach wykorzystano następujące zestawy grafów:

- zestaw grafów losowych o gęstości 0,1
- zestaw grafów losowych o gęstości 0,2
- zestaw grafów losowych o gęstości 0,3
- zestaw grafów losowych o gestości 0,4

<sup>1</sup>http://igraph.sourceforge.net/

- zestaw grafów losowych o gęstości 0,5
- zestaw grafów losowych o gęstości 0,6
- zestaw grafów losowych o gęstości 0,7
- zestaw grafów losowych o gęstości 0,8
- zestaw grafów losowych o gęstości 0,9
- zestaw grafów pełnych

W każdym zestawie znalazły się grafy o liczbie wierzchołków: 10, 20, 30, 40, 50, 60, 70, 80, 90, 100.

Podczas analizy zbadane zostały dwa przypadki:

- wpływ liczby wierzchołków dla grafów o ustalonej gęstości,
- wpływ gestości dla grafów o ustalonej liczbie wierzchołków.

### 6.1 Analiza poprawności działania algorytmu

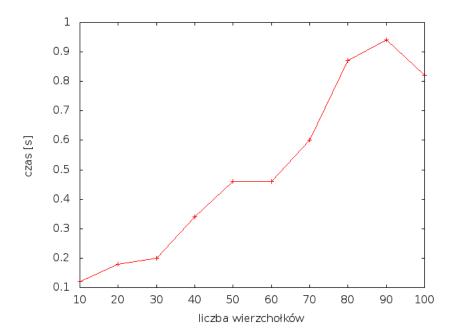
Przed przystąpieniem do właściwej analizy działania algorytmu została zweryfikowana poprawność jego implementacji. Do testowania poprawności działania programu wykorzystana została biblioteka igraph. Szczegółowy schemat testowania został przedstawiony w rozdziale 5.1. Testy zostały przeprowadzone na zestawie grafów opisanych na początku niniejszego rozdziału i nie wykazały błędów ani problemów z działaniem algorytmu.

# 6.2 Analiza czasów wykonania algorytmu

Dla każdego zestawu grafów dokonane zostały pomiary czasu działania algorytmu. Wyniki zostały zamieszczone poniżej.

Tabela 1: Statystyki czasowe dla zestawu grafów o gęstości 0,1

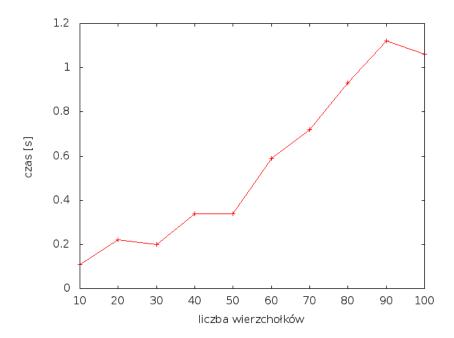
Liczba wierzchołków	Liczba największych klik	Czas [s]
10	5	0.12
20	2	0.18
30	2	0.20
40	8	0.34
50	16	0.46
60	37	0.46
70	53	0.60
80	1	0.87
90	3	0.94
100	3	0.82



Rysunek 1: Wykres zależności czasu wykonania od liczby wierzchołków dla grafów o gęstości  $0,\!1$ 

Tabela 2: Statystyki czasowe dla zestawu grafów o gęstości 0,2

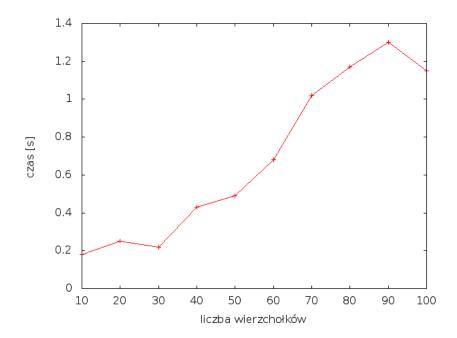
Liczba wierzchołków	Liczba największych klik	Czas [s]
10	9	0.11
20	1	0.22
30	5	0.20
40	5	0.34
50	10	0.34
60	22	0.59
70	1	0.72
80	1	0.93
90	4	1.12
100	10	1.06



Rysunek 2: Wykres zależności czasu wykonania od liczby wierzchołków dla grafów o gęstości 0,2

Tabela 3: Statystyki czasowe dla zestawu grafów o gęstości 0,3

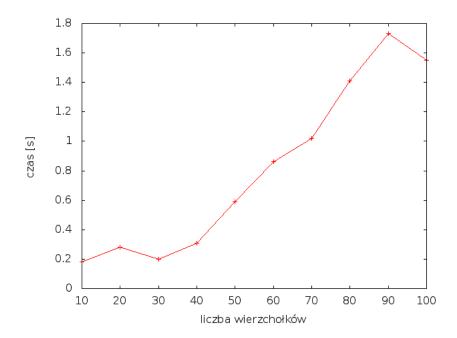
Liczba wierzchołków	Liczba największych klik	Czas [s]
10	3	0.18
20	2	0.25
30	20	0.22
40	1	0.43
50	1	0.49
60	29	0.68
70	1	1.02
80	2	1.17
90	8	1.30
100	9	1.15



Rysunek 3: Wykres zależności czasu wykonania od liczby wierzchołków dla grafów o gęstości  $0,\!3$ 

Tabela 4: Statystyki czasowe dla zestawu grafów o gęstości 0,4

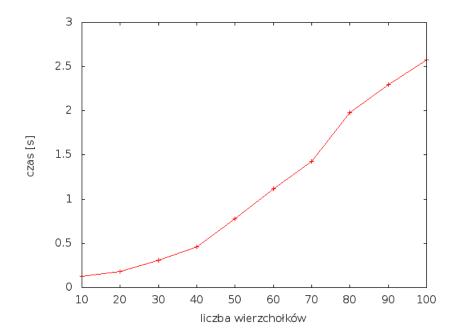
Liczba wierzchołków	Liczba największych klik	Czas [s]
10	7	0.18
20	10	0.28
30	6	0.20
40	6	0.31
50	10	0.59
60	32	0.86
70	5	1.02
80	5	1.41
90	9	1.73
100	49	1.55



Rysunek 4: Wykres zależności czasu wykonania od liczby wierzchołków dla grafów o gęstości  $0,\!4$ 

Tabela 5: Statystyki czasowe dla zestawu grafów o gęstości 0,5

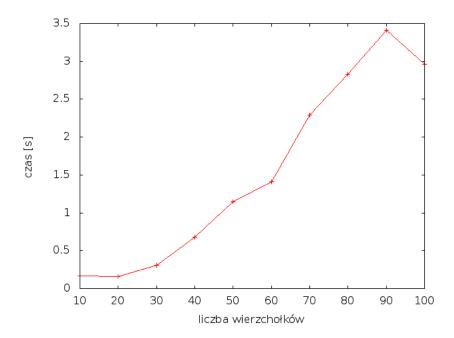
Liczba wierzchołków	Liczba największych klik	Czas [s]
10	12	0.13
20	3	0.18
30	11	0.31
40	2	0.46
50	3	0.78
60	4	1.12
70	7	1.43
80	7	1.98
90	2	2.30
100	17	2.58



Rysunek 5: Wykres zależności czasu wykonania od liczby wierzchołków dla grafów o gęstości  $0,\!5$ 

Tabela 6: Statystyki czasowe dla zestawu grafów o gęstości 0,6

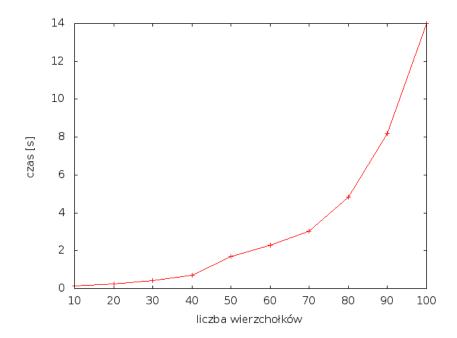
Liczba wierzchołków	Liczba największych klik	Czas [s]
10	1	0.17
20	3	0.16
30	15	0.31
40	1	0.68
50	1	1.15
60	34	1.41
70	5	2.29
80	1	2.83
90	3	3.41
100	48	2.96



Rysunek 6: Wykres zależności czasu wykonania od liczby wierzchołków dla grafów o gęstości  $0,\!6$ 

Tabela 7: Statystyki czasowe dla zestawu grafów o gęstości 0,7

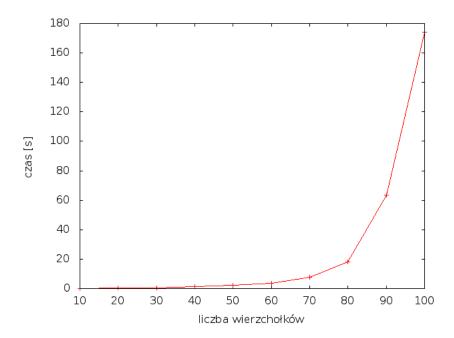
Liczba wierzchołków	Liczba największych klik	Czas [s]
10	4	0.13
20	2	0.24
30	23	0.42
40	2	0.72
50	16	1.68
60	24	2.29
70	1	3.04
80	92	4.83
90	39	8.17
100	52	13.99



Rysunek 7: Wykres zależności czasu wykonania od liczby wierzchołków dla grafów o gęstości  $0,\!7$ 

Tabela 8: Statystyki czasowe dla zestawu grafów o gęstości 0,8

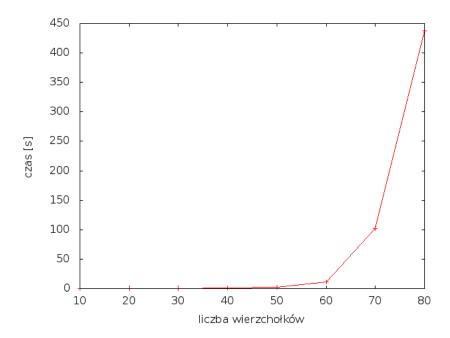
Liczba wierzchołków	Liczba największych klik	Czas [s]
10	3	0.13
20	38	0.28
30	15	0.51
40	2	1.25
50	47	2.45
60	17	3.41
70	5	7.49
80	9	18.25
90	58	63.27
100	29	174.22



Rysunek 8: Wykres zależności czasu wykonania od liczby wierzchołków dla grafów o gęstości  $0,\!8$ 

Tabela 9: Statystyki czasowe dla zestawu grafów o gęstości 0,9

Liczba wierzchołków	Liczba największych klik	Czas [s]
10	2	0.14
20	2	0.22
30	2	0.56
40	5	1.47
50	30	2.46
60	67	11.49
70	127	102.40
80	106	437.49
90	204	3486.84
100	111	9667.70

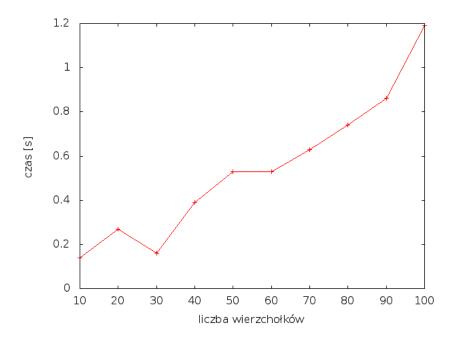


Rysunek 9: Wykres zależności czasu wykonania od liczby wierzchołków dla grafów o gęstości  $0,\!9$ 

# Zestaw grafów pełnych

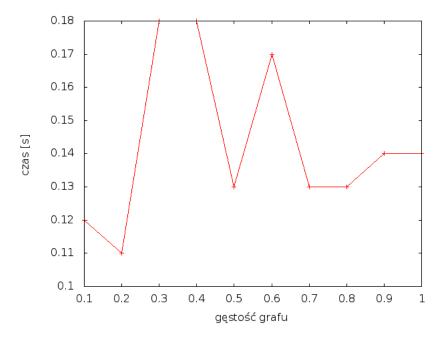
Tabela 10: Statystyki czasowe dla zestawu grafów pełnych

Liczba wierzchołków	Czas [s]
10	0.14
20	0.27
30	0.16
40	0.39
50	0.53
60	0.53
70	0.63
80	0.74
90	0.86
100	1.19



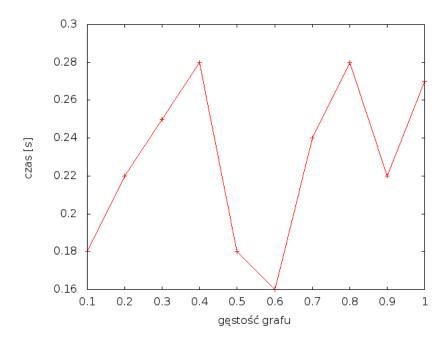
Rysunek 10: Wykres zależności czasu wykonania od liczby wierzchołków dla grafów pełnych

### Zestaw grafów o 10 wierzchołkach



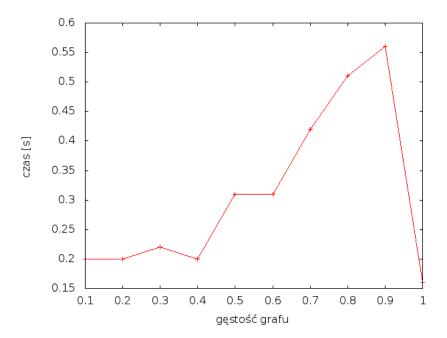
Rysunek 11: Wykres zależności czasu wykonania od gęstości dla grafów o 10 wierzchołkach

### Zestaw grafów o 20 wierzchołkach



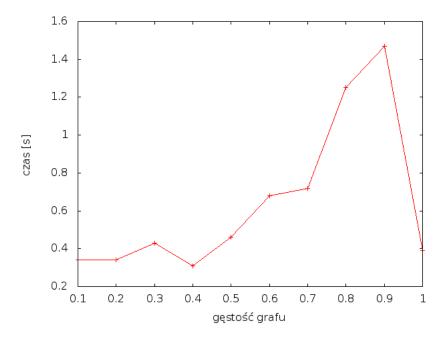
Rysunek 12: Wykres zależności czasu wykonania od gęstości dla grafów o 20 wierzchołkach

### Zestaw grafów o 30 wierzchołkach



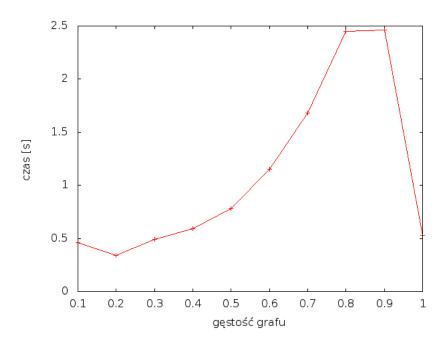
Rysunek 13: Wykres zależności czasu wykonania od gęstości dla grafów o 30 wierzchołkach

### Zestaw grafów o 40 wierzchołkach



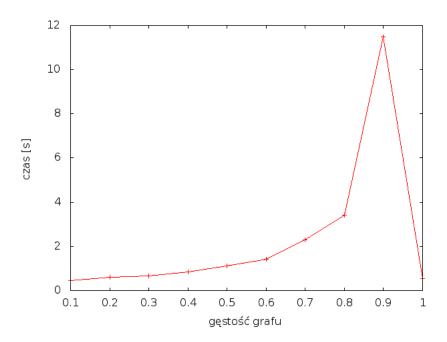
Rysunek 14: Wykres zależności czasu wykonania od gęstości dla grafów o 40 wierzchołkach

### Zestaw grafów o 50 wierzchołkach



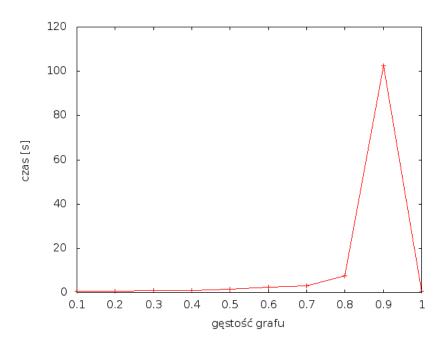
Rysunek 15: Wykres zależności czasu wykonania od gęstości dla grafów o 50 wierzchołkach

# Zestaw grafów o 60 wierzchołkach



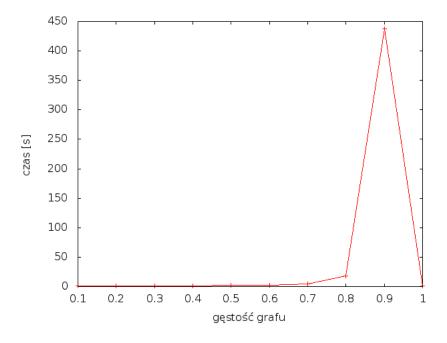
Rysunek 16: Wykres zależności czasu wykonania od gęstości dla grafów o 60 wierzchołkach

### Zestaw grafów o 70 wierzchołkach



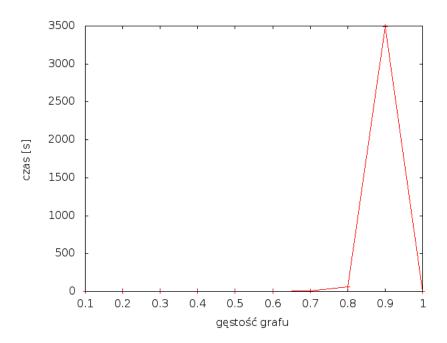
Rysunek 17: Wykres zależności czasu wykonania od gęstości dla grafów o 70 wierzchołkach

### Zestaw grafów o 80 wierzchołkach



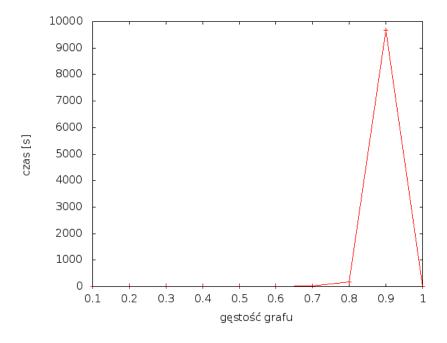
Rysunek 18: Wykres zależności czasu wykonania od gęstości dla grafów o 80 wierzchołkach

### Zestaw grafów o 90 wierzchołkach



Rysunek 19: Wykres zależności czasu wykonania od gęstości dla grafów o 90 wierzchołkach

### Zestaw grafów o 100 wierzchołkach



Rysunek 20: Wykres zależności czasu wykonania od gęstości dla grafów o 100 wierzchołkach

#### 7 Podsumowanie i wnioski

W ramach projektu zrealizowana została aplikacja umożliwiająca znalezienie największej kliki w zadanym grafie. Zaimplementowany algorytm został przetestowany pod kątem poprawnego działania jak również wykonane zostały badania mające na celu zbadanie jego zachowania dla grafów o zróżnicowanej gęstości.

W wyniku eksperymentu przeprowadzonego na zestawie grafów losowych obejmującego grafy o liczbie wierzchołków 10, 20, 30, 40, 50, 60, 70, 80, 100 oraz gęstościach z przedziału 0.1-1 uzyskano rezultaty czasowe zaprezentowane w rozdziałe 6.2.

Analizując otrzymane wyniki można zauważyć, iż dla grafów o gęstościach z przedziału 0.1-0.6 czas wykonania wzrasta w sposób zbliżony do liniowego wraz ze wzrostem liczby wierzchołków grafu. Odmienna sytuacja ma miejsce dla grafów o gęstości z przedziału 0.7-0.9, dla których czas wykonania algorytmu rośnie wykładniczo wraz ze wzrostem liczby wierzchołków. Prawidłowość ta jest szczególnie widoczna dla grafów o gęstości 0.9.

Osobną klasę grafów stanowią grafy pełne, dla których czasy wykonania zależą, podobnie jak w przypadku grafów rzadkich, w sposób zbliżony do liniowego od liczby wierzchołków.

Na podstawie analizy wyników można stwierdzić, że zaimplementowany algorytm silnie zależy zarówno od rozmiaru grafu jak i jego gęstości. W przypadku grafów rzadkich oraz pełnych czasy uzyskiwane przez algorytm nie przekroczyły kilku sekund dla grafów o 100 wierzchołkach. Niestety, w przypadku jednocześnie dużej gęstości i liczby wierzchołków grafu ujawnia się wykładnicza złożoność algorytmu i czas działania drastycznie wzrasta (czego przykładem jest wynik dla grafu o 100 wierzchołkach i gęstości 0,9 sięgający prawie 3 godzin).

# A Zawartość katalogów

Opis zawartości poszczególnych katalogów:

- gis-kliki-java implementacja algorytmu będącego przedmiotem projektu,
- gis-c pomocniczy program generujący rozwiązania referencyjne z wykorzystaniem biblioteki igraph,
- tests pliki dla testów weryfikujących poprawność implementacji:
  - correctness pliki z grafami wykorzystanymi do weryfikacji poprawności algorytmu,
  - performance pliki z grafami wykorzystanymi podczas analizy czasów wykonania algorytmu i jego poprawności,
- doc dokumentacja projektu.

# B Instrukcja obsługi

Aplikacja działa w trybie konsolowym. W celu jej uruchomienia należy wykonać następujące kroki:

- 1. Skompilować kod Javy. W tym celu wystarczy uruchomić skrypt gis-kliki-java/build.sh.
- 2. Przygotować pliki wejściowe.
- 3. Uruchomić program jednym z możliwych sposobów:
  - Ręczne uruchomienie. W katalogu gis-kliki-java należy wykonać następujące polecenie:
    - java -cp bin main/Main < plik\_wejściowy
  - Uruchomienie z wykorzystaniem skryptu. Wraz z programem dostarczone sa dwa skrypty ułatwiające uruchamianie i testowanie aplikacji:
    - run\_basic.sh
      - W wyniku działania zwracany jest czas wykonania oraz znaleziona największa klika.
      - Przykład wykorzystania: run\_test.sh graf1\_in.txt graf2\_in.txt (na wejście można przekazać wiele plików)
    - run\_test.sh
      - Skrypt umożliwia działanie aplikacji w dwóch trybach: standardowym (jak w przypadku run\_basic.sh) oraz rozszerzonym, weryfikującym znalezione rozwiązanie z rozwiązaniami referencyjnymi. Jeśli plik wejściowy nazywał się np. 123\_in.txt, to skrypt poszukuje rozwiązania w pliku o nazwie 123\_out.txt. W przypadku nie znalezienia pliku z rozwiązaniem aplikacja zostaje uruchomiona w trybie standardowym.

Przykład wykorzystania: run\_test.sh graf1\_in.txt graf2\_in.txt (na wejście można przekazać wiele plików)

# Referencje

[1] Bron Coen and Kerbosch Joep. Algorithm 457: finding all cliques of an undirected graph. *Communications of the ACM*, 16(9):575–577, 1973.